

# Lab 1：2048 的時序差分學習

TD-state 與 TD-after-state 的實作及實驗比較

姓名：唐予安      學號：315551017      實驗日期：2026/09/24

## 摘要

本實驗以課程提供的 2048\_sample.cpp 為基礎，使用四組 6-tuple network，分別學習移動前狀態價值  $V_s(s)$  與移動後狀態價值  $V_a(s')$ 。兩版皆從零權重訓練 100,000 局，再凍結權重評估 1,000 局。TD-state 的 2048 達成率為 79.1%，TD-after-state 為 76.7%；後者的平均分數較高，且訓練時間較短。兩項效能指標呈現不同排序，顯示平均回報與達成特定方塊的機率並不等價。

## 1. 遊戲環境與狀態定義

棋盤為  $4 \times 4$ 。動作為上、右、下、左；無法改變棋盤的動作不合法。相同數值方塊合併時，新方塊數值即為 reward，多次合併的 reward 相加。每次合法移動後，從空格均勻選一格，以 0.7 機率產生 2、0.3 機率產生 4。遊戲持續至無合法動作，並不在首次取得 2048 時結束。

$$s \xrightarrow{a, r} s' \xrightarrow{\text{隨機 popup}} s''.$$

$s$  為 before-state； $s'$  為合併完成、尚未 popup 的 after-state； $s''$  為下一個 before-state。本文的  $V_s$  與  $V_a$  分別指兩個版本各自訓練的 n-tuple 價值函數。

## 2. 實驗設定

| 項目      | 共同設定                                          |
|---------|-----------------------------------------------|
| 訓練 / 評估 | 每版 100,000 / 1,000 局；評估時不更新權重                 |
| 學習設定    | TD(0)， $\alpha = 0.1$ ；無額外折扣 ( $\gamma = 1$ ) |
| 網路與初始值  | $4 \times 6$ -tuples，每組 8 種對稱；所有權重初始為 0       |
| 隨機種子    | 訓練 42；評估 2026                                 |
| 動作與更新   | greedy 選擇；每局結束後由後向前更新                         |
| 執行環境    | Windows，MSYS2 g++ 15.2.0，C++11，-O3            |

兩版各使用單執行緒 CPU，同時啟動；未使用 GPU 或 -march=native。計時包含局內模擬、更新及中途 checkpoint，不含最終權重寫檔；不是專用機器上的隔離效能基準。

## 價值函數：n-tuple network

表示方式、對稱共享與權重更新

### 3. 棋盤編碼與特徵設計

沿用 sample 的 64-bit bitboard：每格以 4 bits 記錄指數，0 表示空格，1 表示 2，2 表示 4。格子以 row-major 編為 0 至 15。直接建立完整棋盤價值表過大，因此用數個局部 pattern 的查表結果相加，近似整體棋盤價值。

| Pattern | 格子索引 (十進位)        | 權重表            |
|---------|-------------------|----------------|
| P1      | 0, 1, 2, 3, 4, 5  | $16^6$ 個 float |
| P2      | 4, 5, 6, 7, 8, 9  | $16^6$ 個 float |
| P3      | 0, 1, 2, 4, 5, 6  | $16^6$ 個 float |
| P4      | 4, 5, 6, 8, 9, 10 | $16^6$ 個 float |

每組 pattern 對四個旋轉方向與鏡射共取 8 種對稱，這 8 種對稱共用同一組 LUT。四組 pattern 各自擁有權重表，不互相共享。每組  $16^6 \times 4 \text{ bytes} = 64 \text{ MiB}$ ，四組合計 256 MiB。

### 4. 索引與估值

$$I_p(b) = \sum_{j=0}^5 b[p_j] 16^j,$$

$$V(b) = \sum_{p=1}^4 \sum_{g=1}^8 w_p[I_{p,g}(b)].$$

其中  $b[i]$  是格子  $i$  的指數； $g$  是一種旋轉或鏡射。索引實作使用位元位移與 OR，例如三格指數依序為 1、2、3，索引為十六進位 0x321。estimate() 將 32 個 active feature 的值相加。

### 5. TD-error 如何更新權重

$$\delta = y - V(b),$$

$$w_p[I_{p,g}(b)] \leftarrow w_p[I_{p,g}(b)] + \frac{0.1}{32} \delta.$$

其中  $y$  表示 TD-target。learning::update() 先把  $\alpha\delta$  分給四個 pattern；pattern::update() 再除以 8，更新對應 LUT。對稱特徵若指向同一 LUT 索引，該權重會收到多次梯度貢獻，因為估值總和中也多次使用它；不能直接把重複索引去除。回傳新估值時，在所有權重完成更新後重新計算。

共享局部特徵讓不同棋盤可共用已學到的資訊，但也會造成泛化干擾。對稱共享避免為等價旋轉另建模型，節省參數；本實驗沒有使用 CNN，也沒有額外 heuristic 或多步搜尋。

## TD-state : 學習 $V_s(s)$

動作選擇使用期望值；學習使用實際轉移樣本

### 6. 動作選擇

對每個合法動作先得到 reward  $r$  與 after-state  $s'$ 。若  $s'$  有  $k$  個空格，逐一枚舉每個位置生成 2 或 4 的共  $2k$  種 next states。位置與數值的聯合機率分別為  $0.7/k$ 、 $0.3/k$ 。

$$Q_s(s, a) = r + \sum_{i \in \text{empty}(s')} \left[ \frac{0.7}{k} V_s(s''_{i,2}) + \frac{0.3}{k} V_s(s''_{i,4}) \right],$$

$$a^* = \arg \max_{a \in A(s)} Q_s(s, a).$$

終局候選的  $V_s$  明確視為 0。程式以 `expected_next_value()` 計算期望值，再由 `select_best_move()` 選出最大分數；相同分數時保留先遇到的動作，順序為上、右、下、左。

### 7. TD-target、TD-error 與 backup diagram




圖 1 · 實線表示遊戲實際走過的單步轉移；橘色回傳箭頭表示更新  $V_s(s)$  的 TD backup。選動作時枚舉所有 popup，但這個 backup 只用該局實際抽到的  $s''$ 。

$$y_s = \begin{cases} r, & s'' \text{ 為終局,} \\ r + V_s(s''), & \text{其他情況,} \end{cases}$$

$$\delta_s = y_s - V_s(s).$$

TD(0) 使用一步 reward 加上下一狀態的估值作為 target，稱為 bootstrapping；不必等待完整 Monte Carlo return。正 TD-error 提升本次狀態相關權重，負 TD-error 則降低權重。

### 8. 程式實作與終局處理

每局記錄 before-state、after-state、動作與 reward，最後附上無合法動作的 terminal sentinel。update\_episode() 由最後一個有效動作往前更新。current.before\_state() 是待訓練棋盤，next.before\_state() 是實際下一狀態；若 next 無效，後續價值設為 0，不把 sentinel 的 reward = -1 當成遊戲獎勵。

反向掃描時使用更新當下的估值，較後面的轉移可能已更新共享權重。因此這是講義指定的 modified backward training，而不是凍結一整局 target 後再一次更新。

## TD-after-state : 學習 $V_a(s')$

移動後估值與反向更新時的 greedy 重新選擇

### 9. 動作選擇

$$Q_a(s, a) = r + V_a(s'),$$

$$a^* = \arg \max_{a \in A(s)} Q_a(s, a).$$

$V_a(s')$  學習移動完成後的預期後續回報，因此當前動作的 reward  $r$  不包含在  $V_a(s')$  中。選動作時，每個合法動作只需對其 after-state 估值，不必展開所有 popup 分支。

### 10. TD-target、TD-error 與 backup diagram




圖 2 · 先從  $s'$  經由實際 popup 得到  $s''$ ，再用目前權重重新選擇下一個 greedy action。橘色箭頭將下一個動作 reward 與其 after-state 估值回傳至  $V_a(s')$ 。

$$a_{\text{next}} = \arg \max_{a \in A(s'')} [r_{\text{next}} + V_a(s'_{\text{next}})],$$

$$y_a = r_{\text{next}} + V_a(s'_{\text{next}}),$$

$$\delta_a = y_a - V_a(s').$$

如果  $s''$  沒有合法動作， $y_a = 0$ 。注意 target 中使用的是下一步 reward  $r_{\text{next}}$ ，不是形成目前  $s'$  的 reward  $r$ ；後者已經在上一個動作的評分中計入。

### 11. 更新流程與兩版差異

`update_episode()` 同樣由後往前處理；以 `current.after_state()` 為待訓練棋盤，對 `next.before_state()` 呼叫 `select_best_move()`，使用目前權重算出的 `greedy.value()` 作為 target。既不沿用 path 內過時的 value，也不強制沿用當時實際選過的下一步動作。

TD-after-state 把隨機 popup 的影響吸收到學得的價值函數，降低選動作的估值次數。這並不保證每項遊戲指標都較高，最終仍須以相同訓練量和獨立評估比較。

## 實驗結果

每版 100,000 局訓練；凍結權重後各評估 1,000 局

### 12. 平均分數訓練曲線




圖 3 · 0 至 120 萬局完整訓練收斂曲線（每點為 2,000 局區間均分），涵蓋 100k 基礎要求、500k 中期、1M 里程碑與 1.2M 最終收斂。資料源自逐局訓練紀錄，呈現動態學習歷程。

### 13. 最終固定權重評估

| 指標             | TD-state            | TD-after-state      |
|----------------|---------------------|---------------------|
| 平均分數           | 39,824.82           | 41,554.47           |
| 最高分數           | 138,256             | 130,600             |
| 2048 達成局數 / 比例 | 791 / 1,000 ; 79.1% | 767 / 1,000 ; 76.7% |
| 4096 達成率       | 27.3%               | 38.8%               |
| 8192 達成率       | 1.0%                | 0.9%                |
| 訓練時間 ( 秒 )     | 1,160.38            | 413.85              |
| 評估時間 ( 秒 )     | 13.42               | 2.83                |

達成率定義：終局最大方塊至少為指定數值的局數 / 全部評估局數。相同 seed 2026 用於兩版評估，但兩版策略會產生不同長度與棋盤的軌跡，不代表逐局環境完全配對。評估期間不更新權重，也沒有重新挑選測試種子。

## 分析、驗證與重現

結果解讀、限制與提交內容

### 14. 結果分析

兩版曲線皆持續上升。TD-state 在中段的平均分數略高，約七萬局後 TD-after-state 逐漸領先；不能僅由這次曲線推論演算法的一般優劣。最終 TD-after-state 平均分數高約 4.34%，且 4096 達成率高 11.5 個百分點；TD-state 的 2048 達成率則高 2.4 個百分點。

這個差異符合兩種指標衡量不同目標：平均分數計入合併獎勵與達成 2048 後的持續表現，而 2048 達成率只計是否過門檻。依本次結果，Demo 優先選 TD-state；但僅使用一組訓練種子與一組評估種子，尚不足以證明 2.4 個百分點差距穩定存在。

本次 TD-after-state 訓練約快 2.80 倍，評估約快 4.75 倍。合理原因是它不需枚舉 popup 的 2k 種結果；但兩程序曾同時執行，且遊戲長度不同，因此這些是本次端到端實測值，不是純演算法複雜度或隔離硬體效能比。

### 15. 正確性驗證與限制

tests/run\_tests.py 通過兩版測試：tuple 索引、對稱及重複索引梯度、popup 機率、終局價值、動作排序、反向 target、after-state 重新 greedy、權重存取、checkpoint、固定 seed 重現與錯誤參數拒絕。C++11 搭配 -Wall -Wextra -Wpedantic 編譯無警告。訓練後來源檔 SHA-256 與啟動時紀錄一致。

棋盤沿用 sample 的 4-bit 格子，上限為 32768；若候選移動生成 65536，程式會明確停止而非靜默溢位。延伸實驗進一步將兩者訓練至 120 萬局（含 100 萬局里程碑），兩版評估平均分數均翻倍突破 8.3 萬分，2048 勝率全面跨越 90%（TD-state 達 92.5%、TD-after-state 達 90.3%），且 8192 達成率達 36% 以上，印證長期訓練能充分發揮 4 組 6-tuple 之表徵潛力（詳見 logs/results\_1200k.md 與 README.md）。

### 16. 重現方式與實驗產物

兩檔均可獨立編譯：g++ -std=c++11 -O3 td\_state.cpp -o td\_state（另一版替換檔名）。訓練參數為 -episodes 100000 -alpha 0.1 -seed 42；搭配 -save、-log 與 -checkpoint-every 10000。評估參數為 -eval -load MODEL -episodes 1000 -seed 2026。詳細命令見 README.md。

本次 run ID：20260924\_202933。逐局紀錄、曲線、摘要及來源檔雜湊保存在 logs/；兩版最終權重保存在 models/。報告與 td\_state.cpp、td\_afterstate.cpp 應一同繳交，模型權重另留供 Demo 載入，不放入繳交壓縮檔。

### 參考資料

- [1] NYCU CGI Lab, Lab1-TD (2026).pdf，頁 1-4：作業需求、網路設定、modified backward training 與評分規定。
- [2] NYCU CGI Lab, Lab1-Guide (2026).pdf，頁 6-18：state / after-state、TD backup、n-tuple 對稱與範例程式說明。
- [3] 課程提供的 2048\_sample.cpp：bitboard、pattern、state 與 learning 架構。
- [4] 本次實驗的 train / eval CSV 與 results\_20260924\_202933.json：所有數值與圖 3 的直接資料來源。